

Trabalho Prático

Projeto: *Integração de dados com XML – Países e os seus factos*

LEI – 2023/24

Unidade Curricular: Integração de dados

Docente: Professora Anabela Borges Simões

Autor: Fábio Pereira – 2021129697

Pedro Pereira – 2021130905



ISEC
ENGENHARIA



Apache NetBeans

Índice

1.Introdução.....	3
2. Fontes de Dados	3
2.1. Informações em cada ficheiro XML	3
3. Esquema Global	4
3.1. Funcionalidades Principais	4
3.1.1 Adicionar País (`adicionaPaís`).....	4
3.1.2 Remover País (`adicionaPaís`).....	4
3.1.3 Alterar Continente (`alteraContinente`).....	5
3.1.4 Adicionar Factos (`adicionaFactos`).....	5
3.2. Conclusão.....	5
4. “Wrappers” implementados	5
5. Pesquisas XPath.....	8
6. Criação de ficheiros de output (XSLT/XQuery)	8
7. Conclusão	9

1.Introdução

O objetivo deste projeto foi a criação de um programa em Java composto por vários “Wrappers” que obtenham dados de fontes heterogêneas, distribuídas e autónomas na Web e possibilitem ao utilizador a visualização dos dados de forma integrada sobre países.

O utilizador tem ainda a possibilidade de fazer pesquisas, acrescentar dados que respeitem os esquemas adotados e gerar ficheiros com informação selecionada.

Este trabalho foi realizado na linguagem de programação Java onde foram implementadas expressões regulares nos “Wrappers” e os APIs, JDOM2 e SAXON essencialmente para as transformações entre os vários tipos de ficheiros necessários (XML, DTD, XSD,XSLT e XQuery), onde também foram feitas pesquisas XPath.

2. Fontes de Dados

As fontes de dados de onde foram extraídas as informações relativas aos países foram:

- S1: https://en.wikipedia.org/wiki/nome_país
- S2: https://web.archive.org/web/20231130202159/https://www.countryreports.org/country/nome_país.htm
- S3: https://web.archive.org/web/20231130202159/https://www.countryreports.org/country/nome_país/geography.htm (subdomínio de S2)
- S4: <https://web.archive.org/web/20231130202159/https://www.countryreports.org/country/portugal/facts.htm> (subdomínio de S2)

As informações extraídas foram integradas em dois ficheiros XML: **países.xml** e **factos.xml**

2.1. Informações em cada ficheiro XML

Os ficheiros XML têm na sua composição dados diferentes:

- **países.xml**
 - **Código ISO do país**
 - **Nome do país**

- **Continente do país**
- **Nome do Governante do país**
- **Link para a imagem da bandeira do país**
- **factos.xml**
 - **Código ISO do país**
 - **Nome do país**
 - **Capital do país**
 - **Moeda**
 - **População**
 - **Área em km2**
 - **Crescimento da população**
 - **Cidades mais populosas**
 - **Domínio de internet do país**
 - **Lista de idiomas oficiais**
 - **Lista de países vizinhos**

O esquema da vista unificada também é validado usando **XSD** e **DTD**.

3. Esquema Global

3.1. Funcionalidades Principais

A classe `ModeloGlobal` implementa várias funções essenciais para manipular os dados em ficheiros XML relacionados com os países e os seus factos.

3.1.1 Adicionar País (`adicionaPais`)

Esta função adiciona um novo país ao documento XML.

3.1.2 Remover País (`adicionaPais`)

Esta função remove um país do documento XML com base no nome.

3.1.3 Alterar Continente (`alteraContinente`)

Esta função altera o continente de um país específico.

3.1.4 Adicionar Factos (`adicionaFactos`)

Esta função adiciona um novo conjunto de factos sobre um país ao documento XML.

3.2. Conclusão

A classe `ModeloGlobal` proporciona um conjunto de funções para gerir e manipular dados sobre países em ficheiros XML. Permite adicionar e remover países, alterar informações específicas, como o continente, e adicionar factos detalhados sobre os países, facilitando a integração e a manipulação desses dados de forma estruturada e eficiente

4. “Wrappers” implementados

Para extrair as informações sobre os países das fontes de dados foram implementados “Wrappers”. Estes estão na classe WrappersTP e são os seguintes:

- **obtem_nome_pais**
 - Obter o nome de um país a partir da fonte de dados S1. Faz uma requisição HTTP, salva o conteúdo da página localmente e utiliza expressões regulares para extrair o nome do país.
- **obtem_iso_pais**
 - Obter o código ISO de um país específico a partir da fonte de dados S1. Faz uma requisição HTTP, lê o conteúdo da página salva localmente e utiliza expressões regulares para encontrar e retornar o código ISO.
- **obtem_continente_pais**

-
- Obter o continente ao qual um país pertence, acessando uma página arquivada do site CountryReports. Realiza uma requisição HTTP e salva a página localmente, usando expressões regulares para identificar e retornar o continente.
 - **obtem_nomeGovernante_pais**
 - Obter o nome do governante de um país a partir da fonte de dados S1. Faz uma requisição HTTP, salva a página, e usa expressões regulares para encontrar e retornar o nome do governante (Presidente ou Monarca)
 - **obtem_linkBandeira_pais**
 - Obter o link da imagem da bandeira de um país da sua página na Wikipédia. Realiza uma requisição HTTP, salva a página, e usa expressões regulares para encontrar e retornar o URL da imagem da bandeira
 - **obtem_nome_pais**
 - Obter o nome de um país a partir da fonte de dados S1. Faz uma requisição HTTP, salva o conteúdo da página localmente e utiliza expressões regulares para extrair o nome do país.
 - **Obtem_capital_pais**
 - Obter o nome da capital de um país a partir da fonte de dados S1. Após uma requisição HTTP e leitura do conteúdo salvo, utiliza expressões regulares para encontrar e retornar o nome da capital
 - **obtem_moeda_pais**
 - Obter o nome da moeda oficial de um país a partir da fonte de dados S1. Faz uma requisição HTTP, lê o conteúdo da página salva localmente, e usa expressões regulares para extrair e retornar o nome da moeda.
 - **obtem_dominioInternet_pais**
 - Obter o domínio de internet (TLD) de um país a partir da fonte de dados S1. Realiza uma requisição HTTP, salva a página, e utiliza expressões regulares para encontrar e retornar o domínio de internet.
 - **obtem_idiomasOficiais_pais**

-
- Obter os idiomas oficiais de um país a partir da fonte de dados S1. Faz uma requisição HTTP, lê o conteúdo salvo, e usa expressões regulares para encontrar e retornar os idiomas oficiais
 - **obtem_populacao_pais**
 - Obter a população de um país a partir da fonte de dados S2 e subdomínios. Após a requisição HTTP e leitura do conteúdo salvo, utiliza expressões regulares para encontrar e retornar a população do país.
 - **obtem_areaKM2_pais**
 - Obter a área em quilômetros quadrados de um país a partir da fonte de dados S2 e subdomínios. Faz uma requisição HTTP, lê o conteúdo salvo, e usa expressões regulares para extrair e retornar a área do país.
 - **obtem_crescimentoPopulacao_pais**
 - Obter a taxa de crescimento populacional de um país a partir da fonte de dados S2 e subdomínios. Realiza uma requisição HTTP, salva a página, e utiliza expressões regulares para encontrar e retornar a taxa de crescimento.
 - **obtem_paisesVizinhos_pais**
 - Obter a lista de países vizinhos de um país a partir da fonte de dados S2 e subdomínios. Faz uma requisição HTTP, lê o conteúdo salvo, e utiliza expressões regulares para encontrar e retornar a lista de países vizinhos.
 - **obtem_cidadesPopulosas_pais**
 - Obter uma lista das cidades mais populosas de um país a partir da fonte de dados S1. Realiza uma requisição HTTP, salva a página, e usa expressões regulares para encontrar e retornar a lista das cidades mais populosas.

5. Pesquisas XPath

As pesquisas XPath permitem ao utilizador visualizar informações mais específicas sobre os países. Foram implementadas as seguintes pesquisas:

- Pesquisar pelo nome do país e mostrar a informação relevante
- Pesquisar países de um determinado continente
- Pesquisar os factos de um determinado país
- Qual o país mais populoso?
- Quais os países de um determinado continente, com população acima de um dado valor (dados pedidos ao utilizador)

O utilizador pode ver estas informações mais específicas através da interface gráfica mais propriamente através de **jDialog's**.

6. Criação de ficheiros de output (XSLT/XQuery)

O utilizador também pode gerar ficheiros de output das informações dos países, uma vez que o programa é capaz de gerar ficheiros **XML**, **HTML** e **TXT** que permitem ao utilizador usar por ele próprio as informações geradas. As transformações implementadas foram as seguintes:

- Gerar um ficheiro HTML com uma tabela contendo duas colunas: nome dos países, fotografias das bandeiras dos países
- Gerar ficheiro TXT que mostre a listagem de todos os países
- Gerar um ficheiro XML com informação dos 5 países mais populosos
- Indicar o nome de um continente e gerar ficheiro HTML de fotos das bandeiras dos países desse continente
- Gerar um ficheiro HTML com países por continente (usando XSLT)
- Gerar um ficheiro HTML com cidades mais populosas por país (usando XSLT)
- Gerar um ficheiro HTML com uma tabela contendo a população, área e densidade populacional dos países (usando XSLT)

7. Conclusão

O projeto visava criar um programa em Java para extrair e integrar dados sobre países de diferentes fontes da web, permitindo ao usuário acessar e manipular essas informações de forma unificada. Com base em fontes como a Wikipedia e o site CountryReports, os dados são consolidados em arquivos XML para facilitar sua manipulação.

O programa oferece funcionalidades essenciais, como adicionar, remover e modificar informações sobre os países, e recursos como pesquisas XPath e geração de arquivos de output personalizados usando XSLT e XQuery.

Os "Wrappers" implementados são responsáveis por extrair dados específicos de cada fonte, utilizando expressões regulares para processar o conteúdo das páginas web e obter as informações desejadas.

Em suma, o projeto visa fornecer uma solução abrangente e eficiente para aceder e manipular informações sobre países, integrando dados de fontes heterogêneas e oferecendo recursos de processamento e visualização unificada.